




ROGII 井筒地质预测中的
残差校正与模型筛选

Residual Correction and Model Selection
for ROGII Wellbore Geology Prediction

姓	名:	翁凯乐 何剑宝 冯炳睿 万席宁
学	号:	10245001419 10245001417 10245001411 10245001421
学	院:	统计学院

摘要

本文以 Kaggle 正式赛题 ROGII - Wellbore Geology Prediction 为研究对象，讨论水平井隐藏尾段 TVT 的预测问题。基于官方数据与仓库实验报告，本文首先建立尾部斜率外推的基线模型，随后在按井分组的交叉验证框架下比较了基于几何特征的残差回归模型、基于树模型的残差回归模型、学习型门控残差模型以及诊断上界。实验结果表明，基线模型的整体 RMSE 为 119.933，而基于几何特征的残差回归模型可将 RMSE 降至 15.629，并在可泛化候选中取得最佳表现；基于树模型的残差回归模型与学习型门控残差模型均优于基线，但未超过前者。简单集成与后处理未带来进一步改进。结果说明，在该任务中，稳定的数据边界、严格的交叉验证以及候选模型筛选，比单纯增加模型复杂度更为重要。(<https://github.com/hhhx-lab/ROGII>)

关键词：Kaggle；井筒地质预测；残差回归；交叉验证；模型筛选

Abstract

This paper studies the TVT prediction task in the Kaggle competition ROGII-WellboreGeologyPrediction. Using the official data and repository reports, a tail-slope baseline is first established, followed by comparisons among a geometry-feature residual regressor, a tree-based residual regressor, a learned gating model, and a diagnostic upper bound under well-level GroupKFold validation. The results show that the baseline reaches an overall RMSE of 119.933, while the geometry-feature residual model reduces RMSE to 15.629 and becomes the best deployable candidate. The tree-based residual model and the learned gating model both improve over the baseline but do not outperform the geometry-feature residual model. Simple blending and postprocessing do not yield further gains. These findings indicate that strict validation and candidate selection are more critical than model complexity for this task. (<https://github.com/hhhx-lab/ROGII>)

Keywords: Kaggle; wellbore prediction; residual learning; GroupKFold; model selection

目录

摘要	2
Abstract	3
1 背景介绍	5
2 数据介绍	6
3 数据分析	8
3.1 数据预处理与描述统计	8
3.2 基线模型	9
3.3 残差回归	9
3.4 XGBoost	10
3.5 门控、集成与模型筛选	10
4 结论	12
附录	13

1 背景介绍

ROGII 竞赛关注水平井井筒地质预测问题，具有明确的行业背景。水平井钻探过程中，作业人员需要依据井轨迹、测井曲线及参考地层信息，对地下地质变化作出判断；但地下结构只能通过间接观测获取，且地层可能因弯曲、断裂等因素偏离理想层状形态，因此井筒所处位置与目标地层之间的对应关系具有较强不确定性。基于此，本文研究如何利用水平井钻井数据预测隐藏尾段的 TVT，以提高井筒地质解释的准确性，并为后续轨迹控制与风险识别提供数据支持。

ROGII 竞赛的研究对象是水平井井筒地质预测问题。参赛者需要根据井眼轨迹、已知段测井曲线以及相关参考信息，预测隐藏尾段的 TVT。相关官方页面已在附录中列出。从问题形式上看，该任务既包含沿井轨迹的连续变化，也包含测井曲线形态的延续与对照，因此并不适合仅用单一静态回归方式处理。

本文采用“基线模型 + 残差回归 + 树模型比较 + 门控与筛选”的分析路线。其基本思路是先用一个稳定的外推模型提供下限，再分别考察更灵活的残差回归、树模型与门控策略是否能够在相同验证口径下带来稳定改进。全文安排如下：第二章介绍数据来源、变量含义与样本构造；第三章依次讨论基线模型、残差回归、XGBoost 以及门控、集成与模型筛选；第四章总结主要结论与经验教训。

2 数据介绍

数据来自 Kaggle 官方竞赛提供的训练集与测试集。仓库中每口训练井配有 horizontal CSV、typewell CSV 和 PNG 视觉图；公开可见测试井配有 horizontal CSV 和 typewell CSV。训练井共有 773 口，可见测试井 3 口，样例提交共有 14,151 行；训练 horizontal 的总行数为 5,092,255，训练 hidden target 行数为 3,783,989。公开可见测试集中的 3 口井与训练井重合，因此它只能用于格式核验，不能作为独立验证集。

每口训练井都可以分成已知段和隐藏尾段两部分：当 TVT_input 存在时，表示该位置属于已知段；当 TVT_input 为空时，对应位置就是需要预测的隐藏尾段。本文的模型训练只在训练井内部构造样本与验证折，不把公开可见测试集当作独立验证集使用。

项目	数值 / 字段	说明
训练井 / 可见测试井	773 / 3	训练井用于交叉验证；可见测试井仅用于核验
样例提交行数	14,151	提交格式为 id,tvt
训练 horizontal 总行数	5,092,255	水平井原始行数总和
训练 hidden target 行数	3,783,989	需要预测的隐藏尾段总行数
训练 typewell 行数	773	每口训练井对应一份 typewell 文件
可见测试井 ID	000d7d20、00bbac68、00e12e8b	与训练井重合

表 2-1 ROGII 数据规模概览

本竞赛采用均方根误差（RMSE）作为评价指标。设真实值为 y_i ，预测值为 $\hat{y}_i$ ，测试集样本数为 n ，则

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}.$$

其中， y_i 表示第 i 个样本的真实 TVT， $\hat{y}_i$ 表示对应预测值， n 表示参与评价的样本数。RMSE 越小，说明模型对隐藏尾段 TVT 的预测越准确。

本文后续列出的 RMSE 数值均来自训练井上的按井分组交叉验证预测（OOF），计算口径是在验证折上比较真实值 truth_tvt 与最终预测 final_pred；它们不是 Kaggle 官方 hidden test 的最终分数。

训练 horizontal 的固定列为 MD, X, Y, Z, ANCC, ASTNU, ASTNL, EGFDU, EGFDL, BUDA, TVT, GR, TVT_input；测试 horizontal 的固定列为 MD, X, Y, Z, GR, TVT_input。训练 typewell 的固定列为 TVT, GR, Geology；可见测试 typewell 的固定列为 TVT, GR。由此可见，Geology 只存在于训练 typewell 中，训练 horizontal 的部分地层相关列也属于训练-only 信息，不能作为正式测试阶段的必需输入。

字段	含义 / 作用
MD	测深或井深索引，用于表示沿井轨迹的采样位置
X, Y, Z	井轨迹空间坐标，用于描述轨迹几何形态
GR	自然伽马测井曲线，反映测井响应
TVT	预测目标，即真实 TVT 值
TVT_input	预测起点之前的已知 TVT 段；隐藏尾段对应位置缺失
ANCC	训练-only 地层相关列
ASTNU	训练-only 地层相关列
ASTNL	训练-only 地层相关列
EGFDU	训练-only 地层相关列
EGFDL	训练-only 地层相关列
BUDA	训练-only 地层相关列
Geology	typewell 训练标签；测试集中不存在

表 2-2 主要字段说明

3 数据分析

3.1 数据预处理与描述统计

在建模之前，首先需要确认训练集、测试集与提交格式在字段层面的对应关系。本文的预处理主要包括三步：第一，统一 train/test 的字段布局，并保留测试阶段可见的输入列；训练-only 的地层相关列仅在训练分析中使用，不作为正式测试输入。第二，以 TVT_input 为空的位置定义隐藏尾段，构造 truth_tvt、baseline_tvt 与 residual_target，其中 $\text{residual_target} = \text{truth_tvt} - \text{baseline_tvt}$ 。第三，在基线特征之上继续构造几何特征、GR 特征、typewell 对齐特征和滚动统计特征，其中线性残差模型在进入回归器之前先做标准化。仓库中的样本统计显示，训练 horizontal 的每井长度分布较宽，平均 6,587.650 行，中位数 6,576 行，最短 2,058 行，最长 12,141 行。公开可见测试井分别有 5,278、7,559 和 6,384 行，而需要预测的尾段分别为 3,836、6,014 和 4,301 行。训练 horizontal 中 GR 的缺失率为 29.610%，TVT_input 的缺失率为 74.310%，与“前段已知、后段隐藏”的任务形态一致。

指标	数值	说明
训练 horizontal 每井 rows mean / std / min / median / max	6,587.650 / 1,311.460 / 2,058 / 6,576 / 12,141	原始水平井长度分布较宽
公开可见测试井 rows	5,278 / 7,559 / 6,384	仅用于格式与一致性核验
公开可见测试井 target rows	3,836 / 6,014 / 4,301	公开可见尾段长度
训练 horizontal GR missing rate	29.610%	GR 缺失较多
训练 horizontal TVT_input missing rate	74.310%	与隐藏尾段对应
target rows min / median / max	407 / 4,840 / 10,052	隐藏尾段长度跨度大
known rows min / median / max	851 / 1,703 / 2,392	已知段长度相对较短

表 3-1 ROGII 原始数据的描述统计

typewell 的 Geology 标签分布显著不均衡，最大类 ANCC 为 294,268，最小类 EGFD200 仅为 1。该分布表明，Geology 更适合作为训练诊断或辅助分析变量，而不宜作为测试阶段的硬性输入。另一方面，隐藏尾段越长，基线模型误差越大；在 4k 行以上的尾段区间，基线的平均 RMSE 明显上升。

这些统计说明，该任务同时具有长尾、缺失和类别不均衡三个特点，因此单纯依赖尾部外推难以稳定覆盖全部井段，后续模型需要在相同的按井分组验证口径下比较残差修正是否真正改善了 OOF 表现。

target rows bucket	wells	mean RMSE	说明
0-2k	6	9.709	最短尾段区间，基线尚可
2k-4k	178	30.137	误差开始明显增加
4k-6k	447	57.833	主体区间，基线难度显著上升
6k-8k	128	91.024	长尾段区间，误差进一步放大
8k-12k	14	122.556	最难区间，基线表现最差

表 3-2 基线模型在不同隐藏尾段长度上的表现

3.2 基线模型

基线模型采用尾部斜率外推，其作用在于为后续模型提供稳定的对照组和性能下限。记基线预测为 $\hat{y}_{\text{base}}$ ，则其本质上是利用已知段 `TVT\_input` 的趋势，对隐藏尾段进行延续性外推。虽然这种方法没有显式利用复杂的地层结构，但它具有可解释、稳定和易于复现的优点。基线模型的评估也与后续候选保持同一口径，即在训练井上做按井分组交叉验证，然后用验证折上的真实值与预测值计算 OOF 指标。

指标	RMSE	MAE	P95 abs error	最大绝对误差	说明
基线模型	119.933	53.680	182.780	2552.660	对照组

表 3-3 基线模型的整体表现

从分段结果看，基线模型在短尾段上误差较小，但当隐藏尾段长度增加时，误差迅速增大，说明单纯依赖尾部外推并不足以覆盖较长的结构延续区间。

3.3 残差回归

残差回归的核心思想是先由基线模型给出一个初始预测，再对基线误差进行二次建模。若记真实值为 y ，基线预测为 $\hat{y}_{\text{base}}$ ，则残差目标可写为

$$r = y - \hat{y}_{\text{base}}, \quad \hat{y} = \hat{y}_{\text{base}} + \hat{r}(x).$$

其中， x 表示可用于测试阶段的几何信息、已知段长度、GR 缺失结构及若干滚动统计量。基于几何特征的残差回归模型采用标准化后的线性回归器，其主要参数为 $\alpha = 5 \times 10^{-4}$ 、`max_iter` = 30、`tol` = 10^{-3} 、`early_stopping` = `True`、`validation_fraction` = 0.1、`n_iter_no_change` = 3 与 `average` = `True`。该模型在训练井上按井分组进行交叉验证，避免同一口井同时出现在训练与验证两侧。训练时还对每口井使用按行数归一化的样本权重，以减少长井对损失函数的支配；在最终可泛化候选中，几何残差模型与树模型都采用全量训练行进行拟合，而不是先做强行抽样。后续的门控模型、门控模型与集成候选也都沿用同一残差目标与同一交叉验证口径，因此各候选的 RMSE 可以直接比较。

方法	角色	RMSE	MAE	P95 abs error	改善 / 退化井
基线模型	对照组	119.933	53.680	182.780	-
基于几何特征的残差回归模型	线性残差回归	15.629	11.173	31.945	632 / 141

表 3-4 基线模型与基于几何特征的残差回归模型比较

从结果看，基于几何特征的残差回归模型将 RMSE 从 119.933 降至 15.629，说明在相同验证口径下，残差建模显著优于单纯外推。与此同时，仍有 141 口井出现退化，表明残差回归不能无条件替代基线，而应与基线共同构成候选比较体系。

3.4 XGBoost

XGBoost 属于梯度提升树模型，能够通过逐步叠加强学习器捕捉非线性关系和特征交互。与线性残差回归相比，树模型理论上具有更强的拟合能力，但也更依赖特征信息的完整性以及样本结构的稳定性。本文仍然保持相同的残差目标，即以 $y - \hat{y}_{\text{base}}$ 作为监督信号，再在相同的按井分组交叉验证框架下进行比较。XGBoost 采用较为保守的参数设置，目的不是追求极端拟合，而是在相同 OOF 口径下检验更高复杂度的模型是否能够稳定优于线性残差回归。

方法	关键设置
基于树模型的残差回归模型	<code>n_estimators = 30, max_depth = 4, learning_rate = 0.05, subsample = 0.9, colsample_bytree = 0.9, reg_lambda = 1.0, tree_method = hist, n_jobs = 1</code>

表 3-5 基于树模型的残差回归模型参数设置

方法	角色	RMSE	MAE	P95 abs error	改善 / 退化井
基线模型	对照组	119.933	53.680	182.780	-
基于几何特征的残差回归模型	线性残差回归	15.629	11.173	31.945	632 / 141
基于树模型的残差回归模型	树残差回归	31.473	13.748	34.654	626 / 147

表 3-6 树模型与线性残差回归模型比较

从交叉验证结果看，基于树模型的残差回归模型优于基线模型，但明显弱于基于几何特征的残差回归模型。结合当前特征信息与样本结构可以看出，树模型虽然复杂度更高，但并未自动带来更优结果，说明在该任务中模型复杂度必须与特征质量和验证表现相匹配。

3.5 门控、集成与模型筛选

门控模型可写为

$$\hat{y} = \hat{y}_{\text{base}} + \hat{\alpha}(x)\hat{r}(x),$$

其中 $\hat{\alpha}(x)$ 表示对残差的信任程度。学习型门控残差模型通过回归方式学习 α ，其交叉验证预测 RMSE 为 19.818，优于基线，但仍未超过基于几何特征的残差回归模型。诊断上界则通过每口训

练井自身的真值搜索最佳 α ，其 RMSE 为 13.381；由于该过程依赖同井真值，因此只能作为上界分析，不能作为最终泛化模型。几何残差模型的 α 还做过离散搜索，候选点为 0.0、0.25、0.5、0.75 和 1.0，其中 $\alpha = 1.0$ 的 OOF 表现最好。门控、集成与候选筛选的作用，是在同一套 OOF 结果上判断“更复杂的组合”是否真的比单一残差模型更稳健，而不是把公开可见测试集当作调参依据。

候选	RMSE	说明
基于几何特征的残差回归模型	15.629	最终可泛化候选
学习型门控残差模型	19.818	可泛化门控候选
诊断上界	13.381	仅作上界分析

表 3-7 门控模型比较

集成结果显示，简单组合并未优于基于几何特征的残差回归模型：`optimized` 与该模型持平，而 `balanced`、`aggressive` 和 `conservative` 均明显恶化。

候选	RMSE	说明
基于几何特征的残差回归模型	15.629	基准候选
<code>optimized</code>	15.629	与基准候选持平
<code>balanced</code>	42.223	明显劣化
<code>aggressive</code>	59.901	明显劣化
<code>conservative</code>	109.595	明显劣化

表 3-8 集成候选的交叉验证结果

候选模型筛选时，先以基线模型的覆盖范围为参照，要求候选的行覆盖率和井覆盖率均不低于 95%；随后在满足覆盖条件的候选中按完整覆盖下的交叉验证预测 RMSE 排序。若候选之间的差异落在 0.01 的容忍区间内，则进一步比较最差井 RMSE、退化井数量与 P95 绝对误差。最终被选中的候选是基于几何特征的残差回归模型，其覆盖率为基线完全一致（1.000 / 1.000），且交叉验证预测 RMSE 最低。

后处理同样需要遵循交叉验证约束。仓库中的后处理候选将 RMSE 从 15.629 恶化到 69.926，因此未被采纳。

候选	RMSE before	RMSE after	结论
后处理候选	15.629	69.926	拒绝

表 3-9 后处理结果

4 结论

本文围绕 ROGII 井筒地质预测任务，基于官方资料与仓库实验报告，对尾部外推基线、残差回归、树模型、门控、集成与模型筛选进行了统一比较。结果表明，在当前任务设定下，最有效的策略并不是单纯提高模型复杂度，而是先建立可审计的基线模型，再在按井分组的交叉验证框架下验证残差修正是否真正带来稳定改进。就可泛化候选而言，基于几何特征的残差回归模型表现最佳，并被筛选为最终候选；基于树模型的残差回归模型与学习型门控残差模型可作为对照，但并未超过前者。

结合交叉验证和结果对比可以看出，XGBoost 虽然具有更强的非线性拟合能力，但在当前特征信息和样本结构下并未优于结构更简单的残差回归模型。这一结果提示，在类似的井筒预测任务中，模型复杂度不应被视为提升性能的充分条件，而应结合数据规模、结构特征与验证结果进行选择。对于本研究而言，更有价值的经验是：首先保证验证边界清晰，其次再讨论模型表达能力是否足够。

附录

A. 数据与任务说明

- 官方竞赛页面: <https://www.kaggle.com/competitions/rogii-wellbore-geology-prediction/overview>
- 官方数据页面: <https://www.kaggle.com/competitions/rogii-wellbore-geology-prediction/data>
- 官方规则页面: <https://www.kaggle.com/competitions/rogii-wellbore-geology-prediction/rules>

公开可见测试集与训练集重合，因此只能用于格式核验与脚本一致性检查，不应作为独立验证集。

B. 数据统计与任务难点

下面的统计用于支撑正文对任务难点的判断。

统计项	数值	说明
训练 horizontal 每井 rows mean / std / min / median / max	6,587.650 / 1,311.460 / 2,058 / 6,576 / 12,141	原始水平井长度分布较宽
公开可见测试井 rows	5,278 / 7,559 / 6,384	仅用于格式与一致性核验
公开可见测试井 target rows	3,836 / 6,014 / 4,301	公开可见尾段长度
训练 horizontal GR missing rate	29.610%	GR 缺失较多
训练 horizontal TVT_input missing rate	74.310%	与隐藏尾段对应
训练 horizontal ANCC missing rate	0.900%	训练-only 地层列少量缺失
训练 horizontal EGFDL missing rate	0.120%	训练-only 地层列少量缺失
target rows min / median / max	407 / 4,840 / 10,052	隐藏尾段长度跨度大
known rows min / median / max	851 / 1,703 / 2,392	已知段长度相对较短
target GR missing q0 / q25 / q50 / q75 / q90 / max	0.007 / 0.131 / 0.303 / 0.498 / 0.595 / 0.812	目标段 GR 缺失率分布

表 B-1 数据统计补充

label	count	位置	说明
ANCC	294,268	最多	typewell 标签最常见类别
EGFDL	205,397	较多	次高频类别
ASTNL	172,223	较多	高频类别
BUDA	140,640	较多	高频类别
ASTNU	118,025	较多	高频类别
EGFDU	70,013	较多	高频类别
EGFD200	1	最少	极端稀有类别

表 B-2 typewell Geology 类别分布补充

target rows bucket	wells	mean RMSE	median RMSE	max RMSE
0-2k	6	9.709	9.617	17.739
2k-4k	178	30.137	21.488	114.625
4k-6k	447	57.833	39.775	1465.970
6k-8k	128	91.024	47.382	1434.250
8k-12k	14	122.556	119.480	264.742

表 B-3 基线模型在不同隐藏尾段长度上的表现

C. 完整实验结果

下表汇总可泛化候选与诊断上界的完整交叉验证结果。

方法	RMSE	MAE	P95 abs error	退化并数
基线模型	119.933	53.680	182.780	-
基于几何特征的残差回归模型	15.629	11.173	31.945	141
基于树模型的残差回归模型	31.473	13.748	34.654	147
学习型门控残差模型	19.818	13.984	41.698	120
诊断上界	13.381	9.468	27.353	0

表 C-1 主要候选模型的完整交叉验证结果

alpha	RMSE	MAE	P95 abs error	说明
1.00	15.629	11.173	31.945	选定值
0.75	33.608	18.244	57.661	明显变差
0.50	61.491	29.305	97.753	明显变差
0.25	90.550	41.300	140.564	明显变差
0.00	119.933	53.680	182.780	退化为基线

表 C-2 几何残差模型的 alpha 搜索结果

候选	RMSE before	RMSE after	结论	说明
geometry	15.629	69.926	拒绝	后处理护栏失败
optimized	15.629	15.629	持平	与 geometry 持平
balanced	42.223	-	变差	不优于 geometry
aggressive	59.901	-	变差	不优于 geometry
conservative	109.595	-	变差	不优于 geometry

表 C-3 集成与后处理的完整比较

D. 候选筛选与失败案例

候选筛选先以 baseline 覆盖范围为参照，正式排名要求行覆盖率和井覆盖率均不低于 95%；排序依据完整覆盖下的 OOF RMSE。若候选差异落在 0.01 容忍区间内，则进一步比较最差井 RMSE、退化井数量与 P95 abs error。后处理仅在 OOF 改善时保留，诊断上界不参与自动选择。

候选	状态	OOF RMSE	覆盖率	说明
geometry	selected	15.629	1.000 / 1.000	完整覆盖下 RMSE 最低
xgb	valid	31.473	1.000 / 1.000	可泛化但不优于 geometry
learned_gated_geometry	valid	19.818	1.000 / 1.000	可泛化但不优于 geometry
gated_geometry	skipped	13.381	1.000 / 1.000	诊断上界，自动选择中排除
geometry_postprocessed	rejected	69.926	1.000 / 1.000	后处理护栏失败

表 D-1 候选筛选结果补充

well	rows	RMSE	baseline RMSE	相对 baseline
1b1eba53	4,655	69.353	21.986	-47.367
86454a6f	7,964	64.340	29.618	-34.723
5f4d2a52	5,225	59.492	116.714	57.222
2fd68f7b	4,730	58.814	113.337	54.523
ba48188d	4,166	52.960	74.577	21.617
f88ddb26	4,990	51.898	24.210	-27.688
fef8af96	3,826	48.177	110.584	62.407
43e16325	3,720	44.290	45.777	1.487

表 D-2 候选筛选后最差井的典型样例

E. 图表附录

下列图像直接对应报告中的代表性井段，用于说明模型在极端样本上的行为。




图 E-1 基线最差井示例: a959858c




图 E-2 几何残差模型最佳改进井示例：a959858c




图 E-3 几何残差模型最差退化井示例: 1b1eba53